

Analisis Kritis Output Phase 4: Pelabelan Heuristik

Output dari Phase 4 adalah fondasi dari model prediktif kita. Kita telah berhasil menciptakan "kunci jawaban" buatan yang akan digunakan mesin untuk belajar. Mari kita bedah hasilnya secara mendalam.

1. Evaluasi Output: Apakah Hasil Ini Bagus?

Jawaban Singkat: Ya, hasil ini justru sangat bagus dan sesuai dengan ekspektasi.

Penjelasan Rinci:

Melihat hasil 99 Pengguna Biasa vs. 1 Terindikasi Buzzer mungkin pada awalnya terlihat mengecewakan, tetapi ini adalah hasil yang sangat positif dan menunjukkan keberhasilan dari metode kita. Inilah alasannya:

1. **Konfirmasi Hipotesis Awal:** Sejak awal, kita memprediksi bahwa dataset akan **sangat tidak seimbang (highly imbalanced)**. Output ini secara kuantitatif membuktikan hipotesis tersebut. Ini adalah temuan kunci.
2. **Spesifisitas Aturan yang Tinggi:** Hasil ini menunjukkan bahwa **aturan heuristik yang kita buat sangat ketat dan spesifik**. Hanya akun yang benar-benar memenuhi SEMUA empat kriteria ekstrem yang berhasil ditandai. Ini bagus, karena artinya label 1 (buzzer) yang kita buat memiliki **tingkat kepercayaan yang sangat tinggi**. Lebih baik memiliki sedikit label positif yang akurat daripada banyak label positif yang diragukan.
3. **Validasi Profil Buzzer:** Mari kita lihat akun thelastgoodbtch yang berhasil dilabeli. Akun ini memiliki:
 - o in_degree: 0
 - o betweenness: 0.0
 - o out_degree: 4 (di atas ambang batas)
 - o narrative_similarity: 0.74 (di atas ambang batas)Profil ini cocok 100% dengan definisi teoretis buzzer yang kita susun: terisolasi, tidak menjadi jembatan, aktif menyebar, dan narasinya seragam. Ini membuktikan bahwa fitur kita berhasil menangkap sinyal yang benar.

Grafik distribusi ini secara visual mengkonfirmasi betapa ekstremnya ketidakseimbangan kelas, yang merupakan informasi vital untuk Phase 5.

2. Kesesuaian & Keberhasilan Algoritma

a. Apakah Algoritma Ini Cocok?

Ya, algoritma Heuristic Labeling sangat cocok untuk masalah ini. Dalam banyak masalah dunia nyata, kita tidak memiliki "ground truth". Tidak ada yang memberi kita daftar pasti akun buzzer. Metode heuristik adalah pendekatan standar industri dan akademik untuk

menciptakan **label proksi (proxy labels)** yang cukup baik untuk memulai proses pemodelan. Ini jauh lebih baik daripada tidak memiliki label sama sekali.

b. Bagaimana Algoritma Ini Berhasil?

Keberhasilan algoritma ini terletak pada kemampuannya untuk **menerjemahkan pengetahuan domain kualitatif menjadi aturan kuantitatif yang dapat dieksekusi**.

- **Tujuan:** "Temukan akun yang terisolasi, hanya menyebar narasi seragam, dan tidak berdiskusi."
- **Keberhasilan Algoritma:** Algoritma ini berhasil menerjemahkan tujuan tersebut menjadi kode: `if (in_degree == 0) and (betweenness == 0) and (similarity > 0.73) and (out_degree > 1)`.

Ia berhasil menyaring 100 akun dan menemukan satu akun yang paling cocok dengan "sidik jari" buzzer yang kita definisikan.

3. Permasalahan & Keterbatasan yang Ditemukan

Analisis kritis mengharuskan kita untuk mengidentifikasi kelemahan. Berikut adalah beberapa masalah potensial:

a. Permasalahan pada Algoritma (Heuristic Labeling):

1. **Sifat Biner yang Kaku:** Aturan kita sangat kaku. Sebuah akun yang memiliki `in_degree = 1` (hanya karena satu balasan) akan langsung gagal memenuhi syarat dan diberi label 0, meskipun fitur lainnya sangat tinggi. Algoritma ini tidak bisa menangkap "**area abu-abu**"—akun yang *hampir* seperti buzzer.
2. **Sensitivitas Terhadap Ambang Batas (Threshold):** Pemilihan kuantil ke-75 (0.75) adalah sebuah pilihan. Jika kitaurunkannya menjadi 0.70, kita mungkin akan mendapatkan lebih banyak akun berlabel 1, tetapi dengan kepercayaan yang sedikit lebih rendah. Ini menunjukkan adanya elemen subjektivitas dalam penentuan aturan.
3. **Tidak Adaptif Terhadap Taktik Baru:** Aturan ini didasarkan pada pola buzzer yang umum diketahui. Jika muncul taktik buzzer baru yang lebih canggih (misalnya, mereka sengaja saling membalas satu sama lain untuk menaikkan `in_degree`), aturan kita saat ini mungkin tidak akan bisa menangkap mereka.

b. Permasalahan pada Dataset (yang Terungkap oleh Algoritma):

1. **Ketidakseimbangan Kelas yang Ekstrem:** Ini adalah masalah terbesar. Model machine learning secara alami akan cenderung memprediksi kelas mayoritas (pengguna biasa). Di Phase 5, kita harus secara eksplisit menggunakan teknik penanganan data tidak seimbang (seperti parameter `scale_pos_weight` atau metode *resampling*) dan metrik evaluasi yang tepat (**Recall** dan **AUC-PR**, bukan Akurasi).
2. **Kepadatan Sinyal yang Rendah:** Fakta bahwa hanya ada satu akun yang memenuhi semua kriteria menunjukkan bahwa "buzzer ideal" menurut definisi kita mungkin jarang ada di dataset ini. Banyak akun mungkin menunjukkan 1 atau 2 perilaku mencurigakan,

tetapi tidak semuanya. Ini membuat tugas klasifikasi menjadi lebih sulit karena batas antara kelas tidak begitu jelas.

3. **Potensi Noise pada Label 0:** Sebanyak 99 akun yang kita beri label 0 (Pengguna Biasa) sebenarnya adalah campuran dari pengguna organik sejati dan akun-akun di "area abu-abu". Ini berarti data latih kita untuk kelas 0 tidak 100% murni, yang bisa sedikit membingungkan model saat berlatih.